

| Όνοματεπώνυμο      | Αριθμός Μητρώου |
|--------------------|-----------------|
| ΜΟΝΟΧΟΛΙΑΣ ΙΩΑΝΝΗΣ | 3230128         |
| ΜΑΡΑΚΗΣ ΜΙΧΑΗΛ     | 3230267         |

## ΑΣΚΗΣΗ 1

11 Άσκηση


α. Δεδομένα 1

Stemplot

```

30 | 3
31 | 0 1
32 | 1 6 7
33 | 4 6
34 | 2 5

```




Δεδομένα 2

Stemplot

```

0 | 0 0 2 8
1 | 2 4
2 |
3 | 2
4 | 2
5 |
6 | 4
7 |
8 |
9 | 0

```




Δεδομένα 3

Stemplot

```

0 | 0 1 6 8
1 | 0 3 5 6 7 7 8 8
2 | 0 0 1 5 6
3 | 0 5 9
4 | 0 1 3 4 6 8
5 | 2 4 8 9 9
6 | 0 6
7 |
8 | 1 6 7 8 9
9 | 4 6

```



Boxplot

b.

#### Δεδομένα 1

- Μέση τιμή = 32.55
- Τυπική απόκλιση = 1.419898
- fivenum = (30.3, 31.1, 32.65, 33.6, 34.5)

Η μέση τιμή και η τυπική απόκλιση συνοψίζουν καλύτερα την κατανομή των δεδομένων, καθώς δεν υπάρχουν outliers που να επηρεάζουν σημαντικά μέση τιμή και τυπική απόκλιση. Επιπλέον, όπως φαίνεται από τα stemplot και boxplot, τα δεδομένα είναι σχεδόν συμμετρικά κατανεμημένα.

#### Δεδομένα 2

- Μέση τιμή = 2.64
- Τυπική απόκλιση = 3.059121
- fivenum = (0.0, 0.2, 1.3, 4.2, 9.0)

Σε αυτή την περίπτωση φαίνεται τόσο από το stemplot όσο και από το boxplot ότι υπάρχει ασυμμετρία στην κατανομή των δεδομένων, διότι συγκεντρώνονται πολλές χαμηλές τιμές και απομένουν λίγες μεσαίες/μεγάλες. Επίσης, η ο συνδυασμός «μεγάλων τιμών» (6.4,9.0) με τις τυπικές τιμές θα επηρεάσει αρκετά τη μέση τιμή και την τυπική απόκλιση. Συνεπώς, η σύνοψη των 5 αριθμών συνοψίζει καλύτερα την κατανομή των δεδομένων.

#### Δεδομένα 3

- Μέση τιμή = 41.15
- Τυπική απόκλιση = 28.26754
- fivenum = (0.0, 17.5, 39.5, 59.0, 96.0)

Παρατηρούμε ότι υπάρχει ελαφρά σχετικά συσσώρευση των δεδομένων σε μικρές και μεσαίες τιμές. Αυτό σημαίνει ότι υπάρχει άνιση/ασύμμετρη κατανομή των μικρομεσαίων τιμών και των μεγάλων. Όμως οι μεγάλες τιμές θα αυξήσουν τη μέση τιμή και την τυπική απόκλιση, καθιστώντας τες ακατάλληλες. Επομένως, θα ήταν προτιμότερη η σύνοψη των 5 αριθμών ώστε να συνοψιστεί καλύτερα η κατανομή των δεδομένων.

c.

#### Δεδομένα 1

Αναμένουμε η πρώτη ομάδα δεδομένων να μπορεί να προσεγγιστεί με ικανοποιητική ακρίβεια από μια καμπύλη κανονικής κατανομής, διότι υπάρχει συμμετρία στην κατανομή των δεδομένων.

| Ποσοστημόρια                              | 25%        | 50%        | 75%        |
|-------------------------------------------|------------|------------|------------|
| Τιμή κατανομής δεδομένων                  | 31.35      | 32.65      | 33.55      |
| Τιμή κανονικής κατανομής $N(\mu, \sigma)$ | 31.59229   | 32.55000   | 33.50771   |
| Απόλυτη διαφορά ποσοστημορίων             | 0.24229317 | 0.10000000 | 0.04229317 |

Πράγματι, παρατηρούμε ότι η κανονική κατανομή με μέση τιμή και τυπική απόκλιση αυτές των δεδομένων προσεγγίζει σε αρκετά ικανοποιητικό βαθμό την κατανομή των δεδομένων, όπως αναμενόταν

```

5 #Δεδομένα 1
6 d1 <- c(30.3, 31.0, 31.1, 32.1, 32.6, 32.7, 33.4, 33.6, 34.2, 34.5)
7 head(d1)
8
9 #Υπολογισμός μέσης τιμής,τυπικής απόκλισης
10 #και σύνοψης των 5 αριθμών
11 fivenum(d1)
12 m1 <- mean(d1)#Μέση τιμή δεδομένων 1
13 s1 <- sd(d1)#Τυπική απόκλιση δεδομένων 1
14
15 quantiles <- seq(0.25, 0.75, by = 0.25)#Ποσοστημόρια προς έλεγχο
16
17 q_values1 <- quantile(d1, quantiles)#Τιμή ποσοστημορίων για τα δεδομένα 1
18
19 norm_values1 <- qnorm(quantiles, mean = m1, sd = s1)#Τιμή ποσοστημορίων
20 #για την κανονική κατανομή με μέση τιμή m1 και τυπική απόκλιση s1
21
22 diff1 <- abs(q_values1 - norm_values1)#Απόλυτη τιμή διαφοράς των τιμών των ποσοστημορίων

```

**Σημείωση:** Τα δεδομένα του πίνακα υπολογίστηκαν σε υπολογιστή με τη γλώσσα R, με το διπλανό τμήμα κώδικα. Αντίστοιχα υπολογίστηκαν τα δεδομένα των άλλων δύο πινάκων.

## Δεδομένα 2

Αναμένουμε η δεύτερη ομάδα δεδομένων να μην μπορεί να προσεγγιστεί με ικανοποιητική ακρίβεια από μια καμπύλη κανονικής κατανομής, διότι υπάρχει ασυμμετρία στην κατανομή των δεδομένων και συσσώρευση πολλών τιμών στο κάτω άκρο όπως φαίνεται και από το stemplot.

| Ποσοστημόρια                    | 25%       | 50%       | 75%       |
|---------------------------------|-----------|-----------|-----------|
| Τιμή κατανομής δεδομένων        | 0.35      | 1.30      | 3.95      |
| Τιμή κανονικής κατανομής N(μ,σ) | 0.5766541 | 2.6400000 | 4.7033459 |
| Απόλυτη διαφορά ποσοστημορίων   | 0.2266541 | 1.3400000 | 0.7533459 |

Από τα αποτελέσματα σύγκρισης των ποσοστημορίων φαίνεται, όπως αναμενόταν, απόκλιση στις τιμές των ποσοστημορίων της κανονικής κατανομής με μέση τιμή και τυπική απόκλιση αυτές των δεδομένων από την πραγματική κατανομή των δεδομένων. Αυτή η απόκλιση αναδεικνύει την ασυμμετρία των δεδομένων.

## Δεδομένα 3

Αναμένουμε η τρίτη ομάδα δεδομένων να μην μπορεί να προσεγγιστεί με ικανοποιητική ακρίβεια από μια καμπύλη κανονικής κατανομής, διότι υπάρχει ασυμμετρία στην κατανομή των δεδομένων και συσσώρευση πολλών τιμών στο κάτω άκρο όπως φαίνεται και από το stemplot.

| Ποσοστημόρια                    | 25%      | 50%      | 75%      |
|---------------------------------|----------|----------|----------|
| Τιμή κατανομής δεδομένων        | 17.5     | 39.50    | 59.00    |
| Τιμή κανονικής κατανομής N(μ,σ) | 22.08383 | 41.15000 | 60.21617 |
| Απόλυτη διαφορά ποσοστημορίων   | 4.333834 | 1.650000 | 1.216166 |

Παρατηρούμε ότι στην Τρίτη ομάδα δεδομένων υπάρχει μεγάλη διαφορά της κανονικής κατανομής με μέση τιμή και τυπική απόκλιση αυτές των δεδομένων στο ποσοστημόριο Q1. Η κατανομή των δεδομένων έχει πιο χαμηλή τιμή σε εκείνο το ποσοστημόριο και αυτό οφείλεται στην μεγάλη συχνότητα με την οποία εμφανίζονται μικρές τιμές. Οι διαφορές των ποσοστημορίων εξομαλύνονται στη συνέχεια.

**ΑΣΚΗΣΗ 2**

**a.**

Τα δεδομένα προέρχονται από την ιστοσελίδα Basketball-Reference και συγκεκριμένα μεταφορτώθηκαν τοπικά σε μορφότυπο csv από τον σύνδεσμο [https://www.basketball-reference.com/leagues/NBA\\_2026\\_per\\_game.html](https://www.basketball-reference.com/leagues/NBA_2026_per_game.html). Τα δεδομένα παρουσιάζουν τα στατιστικά όλων των αθλητών του NBA για τη σεζόν 2025 – 2026 που βρίσκεται σε εξέλιξη. Περιέχονται 475 περιπτώσεις στα δεδομένα.

**b.**

Τα δεδομένα αποτελούνται από 29 στο σύνολο μεταβλητές εκ των οποίων οι 3 είναι κατηγορικές (Player, Team, Pos) και οι υπόλοιπες 26 ποσοτικές (π.χ. PTS, AST, BLK, TRB , MP).


Πιο συγκεκριμένα:

|                                                  |                                                              |                                                                                                                                                |
|--------------------------------------------------|--------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------|
| Player(όνομα παίκτη): κατηγορική                 | FG(μέσος όρος εύστοχων προσπαθειών): ποσοτική                | 2P(μέσος όρος εύστοχων προσπαθειών για δίποντο) : ποσοτική                                                                                     |
| Team: κατηγορική                                 | FGA(μέσος όρος συνολικών προσπαθειών): ποσοτική              | 2PA(μέσος όρος συνολικών προσπαθειών για δίποντο): ποσοτική                                                                                    |
| Pos(θέση παίκτη): κατηγορική                     | FGpercentage(μέσο ποσοστό εύστοχων προσπαθειών): ποσοτική    | eFGpercentage(μέσο ποσοστό ευστοχίας στα τρίποντα και δίποντα με τα τρίποντα, λαμβάνοντας υπόψιν ότι τα τρίποντα μετράνε περισσότερο):ποσοτική |
| G(παιχνίδια που έχει αγωνιστεί): ποσοτική        | 3P(μέσος όρος εύστοχων προσπαθειών για τρίποντο): ποσοτική   | FT(μέσος όρος εύστοχων ελεύθερων βολών): ποσοτική                                                                                              |
| GS(παιχνίδια που ήταν βασικός): ποσοτική         | 3PA(μέσος όρος συνολικών προσπαθειών για τρίποντο): ποσοτική | FTA(μέσος όρος συνολικών προσπαθειών ελεύθερων βολών):ποσοτική                                                                                 |
| MP(Ο μέσος όρος λεπτών που αγωνίζεται): ποσοτική | 3Ppercantage(μέσο ποσοστό ευστοχίας τριπόντων): ποσοτική     | FTpercentage(μέσο ποσοστό ευστοχίας σε ελεύθερες βολές): ποσοτική                                                                              |
| ORB(μέσος όρος επιθετικών rebounds): ποσοτική    | STL(μέσος όρος κλεψιμάτων): ποσοτική                         | 2Ppercentage(μέσο ποσοστό ευστοχίας τριπόντων): ποσοτική                                                                                       |
| DRB(μέσος όρος αμυντικών rebounds): ποσοτική     | BLK(μέσος όρος blocks): ποσοτική                             | PTS(μέσος όρος πόντων): ποσοτική                                                                                                               |
| TRB(μέσος όρος συνολικών rebounds): ποσοτική     | TOV(μέσος όρος λαθών): ποσοτική                              | Ηλικία: ποσοτική                                                                                                                               |
| AST(μέσος όρος assists): ποσοτική                | PF(μέσος όρος φαουλ του παίκτη): ποσοτική                    |                                                                                                                                                |


c.

## ΑΣΥΜΜΕΤΡΕΣ ΚΑΤΑΝΟΜΕΣ


Histogram of players points




Histogram of players total rebounds



Histogram of players assists




Histogram of players turnovers




Οι 4 παραπάνω μεταβλητές αφορούν τις **ποσοτικές** μεταβλητές των **πόντων**, των **rebounds**, των **λαθών** και των **assists** των παικτών. Και οι 4 παρουσιάζουν δεξιά ασυμμετρία, δηλαδή οι περισσότεροι παίκτες έχουν χαμηλά έως μέτρια νούμερα σε αυτές τις 4 στατιστικές κατηγορίες και έτσι οι αριστερές τιμές παρουσιάζονται σε μεγαλύτερες συχνότητες. Τα ατυπικά σημεία (outliers) οφείλονται στο γεγονός ότι υπάρχουν λίγοι παίκτες στο NBA με πολύ υψηλές επιδόσεις. Συνοψίζοντας, αυτή η ανισοκατανομή των τεσσάρων παραπάνω ποσοτικών μεταβλητών οφείλεται στην ανισότητα των ρόλων των παικτών, από τη μία υπάρχουν λίγοι αστέρες που αντιστοιχούν σε outliers και από την άλλη οι συντριπτικά περισσότεροι παίκτες έχουν πιο περιορισμένο ρόλο στην ομάδα τους.

Histogram of players ages




Στο διπλανό σχήμα φαίνεται η κατανομή των ηλικιών των παικτών. Αυτή η κατανομή μπορούμε να πούμε ότι παρουσιάζει μια ελαφρά δεξιά ασυμμετρία, σίγουρα όχι τόσο έντονη όσο οι 4 προηγούμενες και πιο κοντά σε μια κανονική κατανομή. Αυτό πιθανώς οφείλεται στο ότι οι πιο παραγωγικές για να αγωνίζεται ένα παίκτης σε υψηλό επίπεδο είναι οι σχετικά μικρές(22-28) όπως φαίνεται στο ιστόγραμμα. Υπάρχουν, βέβαια, και outliers που αντιστοιχούν σε λίγους παίκτες μεγάλης ηλικίας( $\geq 35$ ) που συνεχίζουν να αγωνίζονται σε επαγγελματικό επίπεδο.

Histogram of players Games started as basic






Το διπλανό ιστόγραμμα αναπαριστά γραφικά την κατανομή των παιχνιδιών που οι παίκτες ξεκίνησαν ως βασικοί. Παρατηρούμε ότι υπάρχει έντονη δεξιά ασυμμετρία και συγκέντρωση παικτών σε χαμηλές τιμές. Αυτό οφείλεται στο ότι κάθε ομάδα έχει συγκεκριμένους βασικούς παίκτες που ξεκινάνε τους αγώνες συστηματικά, ενώ οι εναπομείναντες περισσότεροι παίκτες πολύ σπάνια θα ξεκινήσουν κάποιο παιχνίδι ως βασικοί.

Histogram of players Games played





Στο διπλανό ιστόγραμμα φαίνεται και μια κατανομή αριστερά ασυμμετρική και είναι αυτή των παιχνιδιών που έπαιξε ο κάθε παίκτης. Παρατηρούμε ότι οι περισσότεροι παίκτες έχουν παίξει σχεδόν σε όλα τα παιχνίδια μέχρι το τελευταίο, ενώ υπάρχουν και λίγοι outliers που αναπαριστούν παίκτες που έχουν χάσει κάποια παιχνίδια, είτε λόγω τραυματισμών είτε λόγω μη χρησιμοποίησής τους από τον προπονητή.

## ΠΕΡΙΠΟΥ ΚΑΝΟΝΙΚΕΣ ΚΑΤΑΝΟΜΕΣ



Οι κατανομές των τριών παραπάνω **ποσοτικών** μεταβλητών φαίνονται να προσεγγίζουν καλύτερα κάποια κανονική κατανομή η κάθε μία. Αφορούν και οι τρεις ποσοστά ευστοχίας(σε δίποντα, τρίποντα και συνολικά). Φαίνεται ότι και οι τρεις έχουν το δικό τους κέντρο και συγκεκριμένα στα δίποντα είναι λίγο πάνω από το 0.5 ενώ στα τρίποντα είναι πιο χαμηλό, λόγω υψηλότερης δυσκολίας, κοντά στο 0.35 και στο συνολικό ποσοστό είναι αναμενόμενα ανάμεσα σε αυτά τα δύο νούμερα στο 0.45. Παρατηρούμε ότι οι αποκλίσεις από το κέντρο δεν είναι τόσο συχνές όσο στα προηγούμενα ασυμμετρικά ιστογράμματα και η ύπαρξη ατυπικών σημείων είναι πιο συμμετρική. Η κατανομή αυτή οφείλεται στο ότι οι παίκτες έχουν σταθερές δεξιότητες και ένας μέσος παίκτης έχει ποσοστά όμοια με αυτά των μέσων τιμών πραγματικά. Επίσης, οι outliers είναι είτε πολύ επιδέξιοι ή χαμηλού επιπέδου παίκτες είτε παίκτες που έχουν ελάχιστες προσπάθειες σουτ και συνεπώς το ποσοστό τους αντιστοιχεί στα άκρα του ιστογράμματος.

## ΠΕΡΙΠΟΥ ΟΜΟΙΟΜΟΡΦΕΣ ΚΑΤΑΝΟΜΕΣ



Τα παραπάνω ιστογράμματα αναπαριστούν γραφικά τις κατανομές της **ποσοτικής** μεταβλητής των λεπτών συμμετοχής κάθε παίκτη ανά παιχνίδι και της **κατηγορικής** μεταβλητής της θέσεως κάθε παίκτη. Παρατηρούμε ότι και οι δύο είναι αρκετά ομοιόμορφα κατανεμημένες, χωρίς πολλούς outliers. Στην πρώτη η ομοιομορφία της κατανομής αντικατοπτρίζει την ανάθεση ρόλων σε κάθε παίκτη της ομάδας και έτσι ο κάθε παίκτης παίζει τα λεπτά που αντιστοιχούν στο ρόλο του (αν είναι μικρός:  $\leq 15$ , μεσαίος:  $(15, 30]$ ) και με outliers τους παίκτες υψηλών επιδόσεων που παίζουν πολλά λεπτά ανά παιχνίδι ( $\geq 35$ ). Οι θέσεις των παικτών είναι και αυτές σχετικά ομοιόμορφα κατανεμημένες, δηλαδή δεν υπάρχουν μεγάλες αποκλίσεις στην εκπροσώπηση των διαφορετικών ρόλων στο γήπεδο. Η μόνη εξαίρεση είναι η θέση SG (Shooting guard) που φαίνεται να υπερισχύει έναντι των υπολοίπων και ίσως να οφείλεται στην τακτική προσέγγιση των ομάδων μέσα στη σεζόν.

d.

Θα υπολογιστούν η α) η μέση τιμή και τυπική απόκλιση και β) η σύνοψη των 5 αριθμών για κάθε μία από τις 11 ποσοτικές μεταβλητές των οποίων οι κατανομές σχολιάστηκαν στο προηγούμενο ερώτημα.

## ΑΣΥΜΜΕΤΡΕΣ ΚΑΤΑΝΟΜΕΣ

|                 | Age      | PTS      | TRB      | AST      | TOV       | GS       | G        |
|-----------------|----------|----------|----------|----------|-----------|----------|----------|
| Μέση τιμή       | 26.07579 | 9.292632 | 3.514947 | 2.134316 | 1.167158  | 4.76     | 10.54316 |
| Τυπική απόκλιση | 4.381412 | 7.252508 | 2.559364 | 2.00955  | 0.9333119 | 5.740639 | 4.562243 |
| Min             | 19       | 0.00     | 0.0      | 0.0      | 0.0       | 0.0      | 1        |
| Q1              | 23       | 3.20     | 1.7      | 0.7      | 0.4       | 0.0      | 7        |
| Διάμεση τιμή    | 25       | 7.40     | 3.0      | 1.5      | 0.9       | 1.0      | 12       |
| Q3              | 29       | 13.45    | 4.8      | 3.0      | 1.7       | 10.5     | 14       |
| max             | 41       | 34.60    | 13.2     | 12.0     | 4.1       | 16.0     | 17       |

Στο προηγούμενο ερώτημα αναλύθηκε, μέσω των γραφικών παραστάσεων, ότι καμία από τις κατανομές αυτών των 7 παραπάνω μεταβλητών δεν μπορεί να προσεγγιστεί από κάποια κανονική κατανομή, καθώς όλες παρουσιάζουν, για διάφορους λόγους, ασυμμετρία και δεν κυμαίνονται κοντά σε κάποιο κέντρο. Επίσης, η υπάρχει σε κάθε μία μεγάλη τυπική απόκλιση σχετικά με το μέγεθος της μέσης τιμής. Συνεπώς, οι μέση τιμή και τυπική απόκλιση καθίστανται ακατάλληλες για να συνοψίσουν τις παραπάνω κατανομές και έτσι η καταλληλότερη επιλογή θα ήταν η σύνοψη των 5 αριθμών.

## ΠΕΡΙΠΟΥ ΚΑΝΟΝΙΚΕΣ ΚΑΤΑΝΟΜΕΣ

|                        | 2Ppercentage | 3Ppercentage | FGpercentage |
|------------------------|--------------|--------------|--------------|
| <b>Μέση τιμή</b>       | 0.5396848    | 0.3362558    | 0.4644161    |
| <b>Τυπική απόκλιση</b> | 0.1631904    | 0.1791785    | 0.1395333    |
| <b>Min</b>             | 0.0000       | 0.0000       | 0.0000       |
| <b>Q1</b>              | 0.4675       | 0.2580       | 0.3970       |
| <b>Διάμεση τιμή</b>    | 0.5335       | 0.3455       | 0.4640       |
| <b>Q3</b>              | 0.6080       | 0.4100       | 0.5045       |
| <b>max</b>             | 1.0000       | 1.0000       | 0.5045       |

Παραπάνω φαίνονται α) η μέση τιμή και τυπική απόκλιση και β) η σύνοψη των 5 αριθμών για κάθε μία από τις 3 ποσοτικές μεταβλητές που αναπαριστούν ποσοστά ευστοχίας των παικτών. Στο προηγούμενο ερώτημα, μέσα από τα ιστογράμματα, παρατηρήσαμε ότι αυτές οι 3 κατανομές προσεγγίζουν καλύτερα κάποια κανονική κατανομή. Συνεπώς, αφού υπάρχει μεγαλύτερη συμμετρία σε αυτές τις κατανομές, η μέση τιμή και τυπική απόκλιση είναι κατάλληλες. Η σύνοψη των 5 αριθμών είναι χρήσιμη σε αυτή την περίπτωση μόνο για τον εντοπισμό outliers.

## ΠΕΡΙΠΟΥ ΟΜΟΙΟΜΟΡΦΕΣ ΚΑΤΑΝΟΜΕΣ

|                        | MP(Minutes played) |
|------------------------|--------------------|
| <b>Μέση τιμή</b>       | 19.32611           |
| <b>Τυπική απόκλιση</b> | 10.06129           |
| <b>Min</b>             | 1.00               |
| <b>Q1</b>              | 10.40              |
| <b>Διάμεση τιμή</b>    | 20.00              |
| <b>Q3</b>              | 28.35              |
| <b>max</b>             | 40.70              |

Η μόνη ποσοτική μεταβλητή που έχει μια περίπου ομοιόμορφη κατανομή είναι αυτή των λεπτών συμμετοχή ανά παιχνίδι. Σε αυτή την περίπτωση υπάρχουν λίγοι outliers με πολλά λεπτά συμμετοχής(>=35) αλλά δεν επιδρούν πολύ στη μέση τιμή καθώς στο μεγαλύτερο μέρος της η κατανομή είναι κοντά στην ομοιόμορφη. Έτσι, εφόσον η επίδραση των outliers είναι ελάχιστοι και δεν μπορούν να αλλοιώσουν το κέντρο, η μέση τιμή και τυπική απόκλιση μας παρέχουν μια αξιόπιστη σύνοψη των δεδομένων.

Παρακάτω φαίνεται και ο σχετικός κώδικας σε R για την εκτέλεση των υπολογισμών του ερωτήματος 2.d

```

123 #FGpercentage
124 FGpercentage = na.omit(players_data$FGpercentage)
125 fn_FGpercentage = fivenum(FGpercentage)
126 m_FGpercentage = mean(FGpercentage)
127 sd_FGpercentage = sd(FGpercentage)
128
129 #2Ppercentage
130 percentage2P = na.omit(players_data$'2Ppercentage')
131 fn_2Ppercentage = fivenum(percentage2P)
132 m_2Ppercentage = mean(percentage2P)
133 sd_2Ppercentage = sd(percentage2P)
134
135 #MP
136 fn_MP = fivenum(players_data$MP)
137 m_MP = mean(players_data$MP)
138 sd_MP = sd(players_data$MP)
139
140 #G
141 fn_G = fivenum(players_data$G)
142 m_G = mean(players_data$G)
143 sd_G = sd(players_data$G)

```

```

98 #Age
99 fn_Age = fivenum(players_data$Age)
100 m_Age = mean(players_data$Age)
101 sd_Age = sd(players_data$Age)
102
103 #PTS
104 fn_PTS = fivenum(players_data$PTS)
105 m_PTS = mean(players_data$PTS)
106 sd_PTS = sd(players_data$PTS)
107
108 #TRB
109 fn_TRB = fivenum(players_data$TRB)
110 m_TRB = mean(players_data$TRB)
111 sd_TRB = sd(players_data$TRB)
112
113 #AST
114 fn_AST = fivenum(players_data$AST)
115 m_AST = mean(players_data$AST)
116 sd_AST = sd(players_data$AST)
117
118 #TOV
119 fn_TOV = fivenum(players_data$TOV)
120 m_TOV = mean(players_data$TOV)
121 sd_TOV = sd(players_data$TOV)


```

```

145 #GS
146 fn_GS = fivenum(players_data$GS)
147 m_GS = mean(players_data$GS)
148 sd_GS = sd(players_data$GS)
149
150 #3Ppercentage
151 percentage3P = na.omit(players_data$'3Ppercentage')
152 fn_3Ppercentage = fivenum(percentage3P)
153 m_3Ppercentage = mean(percentage3P)
154 sd_3Ppercentage = sd(percentage3P)

```


e.



Η σχέση που θα εξεταστεί είναι αυτή ανάμεσα στα λεπτά συμμετοχής ανά αγώνα και πόντων ανά αγώνα. Το scatterplot μέσω του οποίου γίνεται η γραφική αναπαράσταση της σχέσης φαίνεται αριστερά. Η επεξηγηματική μεταβλητή είναι τα λεπτά ανά αγώνα και η μεταβλητή απόκρισης οι πόντοι ανά αγώνα. Φαίνεται καθαρά ότι υπάρχει μια αύξουσα και ισχυρή σχέση μεταξύ των 2 μεταβλητών. Παρατηρούμε, επίσης, πως η αύξηση γίνεται πιο έντονη όταν ξεπερνάμε τα 30 λεπτά. Αυτό πιθανότατα οφείλεται στο ότι οι σημαντικοί παίκτες αγωνίζονται τόσα πολλά λεπτά ανά παιχνίδι και συνεπώς έχουν αρκετά μεγαλύτερη συνεισφορά πόντων από τους υπόλοιπους. Παρόλο που υπάρχει έντονη συσχέτιση μεταξύ των μεταβλητών, η σχέση δεν είναι καθαρά αιτιατή και αυτό διότι μπορεί παίκτες που σκοράρουν πολύ, παίρνουν περισσότερα λεπτά και επομένως μπορεί οι πολλοί πόντοι να είναι η αιτία για περισσότερα λεπτά και όχι το αντίστροφο. Επιπλέον, λόγοι όπως ο ρόλος του παίκτη, η στρατηγική του προπονητή και η ποιότητα του παίκτη επηρεάζουν ταυτόχρονα και τις δύο μεταβλητές, γεγονός που δεν μας επιτρέπει να χαρακτηρίσουμε τη σχέση ως καθαρά αιτιατή.

### ΑΣΚΗΣΗ 3

a.




Στο διπλανό scatterplot φαίνεται η σχέση μεταξύ των ποσοτικών μεταβλητών του **ύψους** και του **νούμερου παπουτσιών** των συμμετεχόντων του ερωτηματολογίου.

**Σχολιασμός κατεύθυνσης και δύναμης της σχέσης των δύο μεταβλητών:** Η σχέση των δύο ποσοτικών μεταβλητών φαίνεται να είναι γραμμική και συγκεκριμένα αύξουσα γραμμική. Αυτό σημαίνει ότι οι ποσοτικές μεταβλητές του ύψους και του νούμερου παπουτσιών των φοιτητών μεταβάλλονται μαζί, δηλαδή όταν αυξάνεται/μειώνεται το ύψος, τείνει να αυξάνεται/μειώνεται και το νούμερο παπουτσιών και αντίστροφα. Η δύναμη της σχέσης θα μπορούσε να χαρακτηριστεί ισχυρή, βάσει της διάταξης των σημείων στο scatterplot, οπότε υπάρχει έντονη συσχέτιση μεταξύ των δύο μεταβλητών.

b.

Ο συντελεστής συσχέτισης των δύο μεταβλητών είναι  $r = 0.8591219$ , γεγονός που αποδεικνύει την ύπαρξη ισχυρής θετικά γραμμικής σχέσης μεταξύ των δύο ποσοτικών μεταβλητών.



Στο διπλανό σχήμα φαίνεται η ευθεία που προέκυψε από την γραμμική παλινδρόμηση ελαχίστων τετραγώνων, για να ελαχιστοποιεί την απόσταση από όλα τα σημεία.

Παρακάτω φαίνονται όλοι οι υπολογισμοί που έγιναν για το ερώτημα 3 σε R.

```

73 #-----
74 #ΕΡΩΤΗΜΑ 3
75 #-----
76 #Ανάγνωση και αποθήκευση των δεδομένων στη μεταβλητή data
77 data <- read.table("survey_data_2025/survey_data_2025.csv", header=TRUE, sep=',')
78 data<-na.omit(data)
79 dim(data)
80 head(data)
81
82
83 #a
84 plot(data$height,data$shoe,xlab="Height",ylab="Shoe number")#Scatterplot των μεταβλητών
85
86 cor(data$height,data$shoe)#Υπολογισμός συντελεστή συσχέτισης
87
88
89 #b
90 model <- lm(data$shoe~data$height)#Υπολογίζει τις παραμέτρους της ευθείας μέσω
91 #της μεθόδου των ελαχίστων τετραγώνων
92 plot(data$height,data$shoe,xlab="Height",ylab="Shoe number")
93 abline(model)#Σχεδιάζει τη γραφική παράσταση της ευθείας ελαχίστων τετραγώνων
94

```