

Όνοματεπώνυμο	Αριθμός Μητρώου
ΜΟΝΟΧΟΛΙΑΣ ΙΩΑΝΝΗΣ	3230128
ΜΑΡΑΚΗΣ ΜΙΧΑΗΛ	3230267

ΑΣΚΗΣΗ 1

a.

Το δείγμα των $n=50$ ρίψεων αποτελεί απλό τυχαίο δείγμα και για $X = 29$ κορώνες έχουμε $X \geq 15$ και $n - X = 21 \geq 15$ και επομένως τα 95% διαστήματα εμπιστοσύνης είναι ακριβή σε ικανοποιητικό βαθμό.

Έχουμε ότι $\hat{p} = \frac{X}{n} = \frac{29}{50} = 0.58$ και για διάστημα εμπιστοσύνης 95% $z_* = 1.959964$ από την R.

Επομένως, το διάστημα εμπιστοσύνης 95% είναι το κάτωθι:

$$\hat{p} \pm z_* \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = [0.4431951, 0.7168049] \text{ όπως υπολογίστηκε στην R.}$$

b.

Θα εφαρμοστεί δίπλευρος έλεγχος σημαντικότητας :

$$H_0: p = 0.5$$

$$H_a: p \neq 0.5$$

Με το p δηλώνεται η συχνότητα εμφάνισης κορώνας στον πληθυσμό, δηλαδή στο σύνολο των άπειρων ρίψεων.

Έχουμε $z = \frac{\hat{p}-0.5}{\sqrt{\frac{0.5(1-0.5)}{50}}} = \frac{0.58-0.5}{\sqrt{\frac{0.5(1-0.5)}{50}}} = 1.131371$ και $p \text{ value} = 2\Phi(-1.13137) = 0.257899$, δηλαδή αρκετά μεγάλο που δεν μας επιτρέπει να απορρίψουμε τη μηδενική υπόθεση.

c.

Πρέπει $z_* \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \leq m \Leftrightarrow n \geq \frac{z_*^2 \hat{p}(1-\hat{p})}{m^2}$, όμως επειδή η δειγματοληψία δεν έχει πραγματοποιηθεί ακόμα, δεν γνωρίζουμε το $\hat{p}$ και επομένως αντικαθιστούμε το $\hat{p}(1-\hat{p})$ με $\frac{1}{4}$ (αφού $\hat{p}(1-\hat{p}) \leq \frac{1}{4}$ με την ισότητα να ισχύει για $p = 1/2$).

Άρα, έχουμε $n \geq \left\lceil \frac{z_*^2}{4m^2} \right\rceil = \left\lceil \frac{1.96^2}{4 \cdot 0.01^2} \right\rceil = \lceil 9603.647 \rceil = 9604$ ρίψεις θα έπρεπε να πραγματοποιηθούν για να γίνει το περιθώριο λάθους στο διάστημα εμπιστοσύνης του ερωτήματος (α) μικρότερο του 0.01.

ΑΣΚΗΣΗ 2

Για την εύρεση του μεγέθους του δείγματος n για κατασκευή 95% διαστημάτων εμπιστοσύνης με περιθώριο σφάλματος 3% στις Η.Π.Α. θα χρησιμοποιηθεί ο τύπος $n \geq \left\lceil \frac{z_*^2}{4m^2} \right\rceil$ με $m = 0.03$. Παρατηρούμε ότι το δεύτερο μέλος δεν εξαρτάται από το μέγεθος του πληθυσμού, παρά μόνο από το περιθώριο λάθος $m=0.03$ και από το z_* , το οποίο καθορίζει το επίπεδο εμπιστοσύνης. Άρα, ένα δείγμα 1100 ατόμων είναι αρκετό για την πραγματοποίηση αντίστοιχων δημοσκοπήσεων στις Η.Π.Α. .

ΑΣΚΗΣΗ 3

a.

Έστω ο δίπλευρος έλεγχος $H_0 : p_1 = p_2$ όπου p_1 το ποσοστό των ανδρών καπνιστών και p_2 το ποσοστό των γυναικών καπνιστών σύμφωνα με τον πίνακα της εκφώνησης που παρουσιάζει έναν πληθυσμό. Σύμφωνα με τον πίνακα έχουμε:

Για τους άνδρες: $n_1 = 30$ (συνολικά άνδρες) και $X_1 = 12$ (καπνιστές άνδρες)

Για τις γυναίκες: $n_2 = 30$ (συνολικά γυναίκες) και $X_2 = 14$ (καπνιστές γυναίκες)

$$\text{Άρα } p_1 = \frac{X_1}{n_1} = 0.4 \quad \text{και } p_2 = \frac{X_2}{n_2} = 0.466$$

Το p_value που θα υπολογιστεί στον z έλεγχο είναι ακριβές καθώς

$$X_1, X_2 > 5 \quad \text{και } n_1 - X_1, n_2 - X_2 > 5$$

Στην R υπολογίζουμε το στατιστικό ελέγχου

$$z <- (p_1 - p_2) / \sqrt{p_hat * (1 - p_hat) * (1/n_1 + 1/n_2)}$$

με $\hat{p} = \frac{X_1 + X_2}{n_1 + n_2}$ και έχω ως αποτελέσματα:

```
p_hat = 0.4333
z = -0.521
p_value = 0.6023319
```

$p_value > 0.5$, επομένως είναι αρκετά μεγάλο για να μην απορριφθεί η H_0 . Με άλλα λόγια δεν υπάρχει σχέση μεταξύ των 2 φύλλων και του καπνίσματος στα δεδομένα του πληθυσμού που παρουσιάζεται στον πίνακα της εκφώνησης.

b.

Αντίθετα με το ερώτημα Α, το 95% διάστημα εμπιστοσύνης το οποίο θα υπολογιστεί δεν θα είναι απόλυτα ακριβές καθώς

$$X_1, X_2 \geq 10 \quad \text{και } n_1 - X_1, n_2 - X_2 \geq 10$$

Σύμφωνα με την R το διάστημα εμπιστοσύνης που υπολογίσαμε είναι:

```
95% Διάστημα Εμπιστοσύνης για (p1 - p2):
z* = 1.96
CI = [-0.317, 0.184]
```

Από τους τύπους στους υπολογισμούς της R:

$$CI_lower <- diff - z_star * \sqrt{p_1 * (1 - p_1) / n_1 + p_2 * (1 - p_2) / n_2}$$

$$CI_upper <- diff + z_star * \sqrt{p_1 * (1 - p_1) / n_1 + p_2 * (1 - p_2) / n_2}$$

c.

Θεωρούμε τον έλεγχο

H_0 : το φύλο δεν σχετίζεται με το κάπνισμα

H_a : το φύλο και κάπνισμα σχετίζονται

Ο πίνακας συνάφειας για τα δεδομένα του πίνακα της εκφώνησης είναι:

	Καπνιστές	Μη Καπνιστές	
Άνδρες	12	18	30
Γυναίκες	14	16	30

	26	34	60
--	----	----	----

d.

Αρχικά βρίσκω τον αναμενόμενο πίνακα τιμών

	Καπνιστές	Μη Καπνιστές	
Άνδρες	$\frac{30 \times 26}{60} = 13$	$\frac{30 \times 34}{60} = 17$	30
Γυναίκες	$\frac{30 \times 26}{60} = 13$	$\frac{30 \times 34}{60} = 17$	30
	26	34	60

Υπολογισμένα στην R αρχικά έχουμε την τιμή στατιστικού ελέγχου του

$$\chi^2 = \frac{(12-13)^2}{13} + \frac{(18-17)^2}{17} + \frac{(14-13)^2}{13} + \frac{(16-17)^2}{17} = \frac{60}{221} = 0.2714932$$

και επίσης σύμφωνα με την R έχω p_value = 0.6023319

```
Τιμή στατιστικού ελέγχου χ^2:
χ^2 = 0.2714932

p_value = 0.6023319
```

Παρατηρούμε πώς το p_value του ερωτήματος Α με το p_value του ερωτήματος Δ είναι ίσα. Αυτό σημαίνει πως οι έλεγχοι z και χ^2 είναι ισοδύναμοι.

ΑΣΚΗΣΗ 4

a.

Έστω p το ποσοστό των κόκκινων smarties στον συγκεκριμένο πληθυσμό. Επομένως 1-p είναι το ποσοστό των μπλέ. Για τον έλεγχο υπόθεσης θα χρησιμοποιήσουμε μονόπλευρο έλεγχο καθώς μας ενδιαφέρει να διαπιστώσουμε αν τα κόκκινα smarties είναι περισσότερα από τα μπλέ. Επομένως θεωρούμε τον έλεγχο υπόθεσης:

$$H_0 : p = \frac{1}{2}$$

$$H_a : p > \frac{1}{2}$$

Σύμφωνα με τα δεδομένα της εκφώνησης:

$$n = 15 + 19 = 34$$

$$X = 19 \text{ κόκκινα κουφέτα}$$

$$p = \frac{19}{34} = 0.55882$$

Το p value που θα βρω από τον z έλεγχο σημαντικότητας είναι ακριβές καθώς ένα κουτάκι με smarties που αγοράζω από κάπου αποτελεί τυχαίο δείγμα καθώς κάθε πακέτο έχει μέσα τυχαίο αριθμό smarties από κάθε χρώμα. Επίσης αν ισχύει η μηδενική υπόθεση τότε ο αναμενόμενος αριθμός από μπλέ και κόκκινα είναι $\frac{n}{2} = \frac{34}{2} = 17 \geq 10$. Επομένως, αφού υπάρχουν περισσότερα από 10 μπλέ και κόκκινα smarties σε κάθε τυχαίο δείγμα τότε το p value από τον z έλεγχο θα είναι ακριβές.

Με $p = 0.55882$

$$H \text{ τιμή του στατιστικού ελέγχου } z = \frac{p - \frac{1}{2}}{\sqrt{\frac{0.5 \times (1 - 0.5)}{n}}} = 0.68599$$

Οπότε με την R υπολογίζω $p \text{ value} = 0.4927167$

```
p = 0.5588235
z = 0.6859943
p_value = 0.4927167
```

Παρατηρούμε πως $p \text{ value} > 0.05$, επομένως δεν μπορούμε να απορρίψουμε την μηδενική υπόθεση. Δηλαδή με άλλα λόγια η διαφορά των μπλε smarties και των κόκκινων δεν είναι στατιστικά σημαντική.

b.

Θα εφαρμόσουμε τον χ^2 έλεγχο καλής προσαρμογής για να ελέξουμε αν τα δεδομένα προέρχονται από την κατανομή του έτους 2009.

H_0 : η κατανομή των χρωμάτων καφέ, κόκκινο, κίτρινο, μπλέ και πράσινο είναι 19.8%, 17.8%, 17.6%, 19.6%, 25.2%.

H_a : η κατανομή χρωμάτων δεν είναι η συγκεκριμένη.

Έχω συνολικά $n = 22 + 19 + 16 + 15 + 8 = 80$ συνολικά κουφέτα

	Δεδομένα	Αναμενόμενες τιμές
Καφέ	22	$80 \times 19.8\% = 15.84$
Κόκκινο	19	$80 \times 17.8\% = 14.24$
Κίτρινο	16	$80 \times 17.6\% = 14.08$
Μπλέ	15	$80 \times 19.6\% = 15.68$
Πράσινο	8	$80 \times 25.2\% = 20.16$

Εφαρμόζουμε τον έλεγχο στην R και έχουμε ως αποτέλεσμα:

Τιμή στατιστικού ελέγχου $\chi^2 = 11.61259$

$p \text{ value} = 0.02047$

```
χ^2 = 11.61259
df = 4
p_value = 0.02047712
```

Παρατηρούμε πως $p \text{ value} < 0.05$. Επομένως η μηδενική υπόθεση δεν ισχύει και συνεπώς δεν είναι η ίδια κατανομή από το 2009. Δηλαδή η κατανομή χρωμάτων θα έχει αλλάξει από τότε.

c.

Αντίστοιχα με μια συσκευασία smarties μια συσκευασία M&Ms θεωρούμε πως είναι ένα τυχαίο δείγμα για τον πληθυσμό των κουφέτων σε μια συσκευασία που έχουν παρασκευαστεί στο εργοστάσιο. Θα εφαρμόσουμε χ^2 έλεγχο για ομοιογένεια για να ελέγξουμε αν τα δείγματα των M&Ms και των smarties λήφθηκαν από πληθυσμούς κουφέτων με την ίδια κατανομή χρωμάτων

H0: τα smarties και τα M&Ms έχουν ίδια κατανομή χρωμάτων

Ha: δεν έχουν την ίδια κατανομή

Από τα δεδομένα φτιάχνουμε τον πίνακα συνάφειας:

	Smarties	M&Ms	άθροισμα
Καφέ	22	10	22+10=32
Κόκκινο	19	12	19+12=31
Κίτρινο	16	20	16+20=36
Μπλέ	15	9	15+9=24
Πράσινο	8	5	8+5=13
	80	56	80+56=136

Εφαρμόζουμε τον έλεγχο στην R και έχουμε ως αποτέλεσμα:

Τιμή στατιστικού ελέγχου $\chi^2 = 4.62617$

p_value = 0.32784

```
χ^2 = 4.626171
df = 4
p_value = 0.3278479
```

Παρατηρούμε πως $p_value > 0.05$, άρα δεν απορρίπτουμε την μηδενική υπόθεση που κάναμε. Άρα τα smarties και τα M&Ms έχουν πράγματι την ίδια κατανομή χρωμάτων.