

Όνοματεπώνυμο	Αριθμός Μητρώου
ΜΟΝΟΧΟΛΙΑΣ ΙΩΑΝΝΗΣ	3230128
ΜΑΡΑΚΗΣ ΜΙΧΑΗΛ	3230267

ΑΣΚΗΣΗ 1

a.

Παρακάτω φαίνεται η κατανομή των τυχαία επιλεγμένων αιτήσεων μέσω stemplot:

```
0 | 44444
0 | 55556688899
1 | 013
1 |
2 |
2 | 8
```

```
1 data1 <- c(82, 55, 58, 94, 86, 45, 42, 36, 41, 130,
2          284, 96, 39, 107, 52, 54, 45, 81, 83, 38)
3 stem(data1)
```

Στο stemplot αυτό, στελέχη είναι οι εκατοντάδες των αριθμών και φύλλα οι δεκάδες(με στρογγυλοποίηση). Παρατηρούμε πώς τα δεδομένα σε γενικές γραμμές δεν είναι πολύ ασύμμετρα, αλλά δεν προσεγγίζουν απόλυτα και κάποια κανονική κατανομή, λόγω ελαφράς υπερίσχυσης των τιμών αριστερά του κέντρου και του ενός ατυπικού σημείου (284). Τα προηγούμενα μπορεί να είναι ενδείξεις ενός μη κανονικά κατανεμημένου πληθυσμού. Παρόλα αυτά ισχύει ότι το μέγεθος του δείγματος $n=20 \geq 15$ και δεν φαίνεται από το δείγμα ότι ο πληθυσμός είναι πολύ ασύμμετρος, οπότε μπορούν να εξαχθούν και έτσι συμπεράσματα με ικανοποιητική ακρίβεια.

Επίσης, ο τρόπος που επιλέχθηκαν τα δεδομένα, δηλαδή με απλή τυχαία δειγματοληψία είναι κατάλληλος για τις μεθόδους συμπερασματολογίας που γνωρίζουμε.

b.

Τύπος για ΔΕ: $\bar{x} \pm t_* s/\sqrt{n}$

$$\bar{x} = 77.4$$

$$s = 55.52467$$

Για $df = n - 1 = 20 - 1 = 19$ και επίπεδο εμπιστοσύνης 95%, προκύπτει από τον πίνακα τιμών της Student's t-κατανομή ότι $t_* = 2.093$.

Από τα παραπάνω προκύπτει ότι ένα 95% διάστημα εμπιστοσύνης είναι το: $[77.4 - 2.093(55.52467)/\sqrt{20}, 77.4 + 2.093(55.52467)/\sqrt{20}] = [51.41395, 103.38605]$.

ΑΣΚΗΣΗ 2

a.

Αφού $n=20$ (όχι πολύ μικρό), ισχύει για την κατανομή του δειγματικού μέσου ότι $\bar{X} \approx N(m, \sigma/\sqrt{n})$. Επομένως, η τυπική απόκλιση του δειγματικού μέσου είναι $\sigma/\sqrt{n} = 12/\sqrt{20} \approx 2.68$

b.

Το λάθος βρίσκεται στο ότι η μηδενική υπόθεση διατυπώνεται για τον δειγματικό μέσο. Γνωρίζουμε πως η μηδενική υπόθεση δεν διατυπώνεται για τα στατιστικά του δείγματος, αλλά για τις παραμέτρους όλου του πληθυσμού.

c.

Με $\bar{x} = 45$ είναι αδύνατον να απορριφθεί η μηδενική υπόθεση και επομένως να υποστηριχθεί η εναλλακτική υπόθεση, αφού η τελευταία υποστηρίζει ότι η μέση τιμή του πληθυσμού είναι > 54 , ενώ ο δειγματικός μέσος όρος δείχνει το αντίθετο.

Πιο συγκεκριμένα, ισχύει ότι $t = \frac{\bar{x}-\mu}{\frac{s}{\sqrt{n}}} = \frac{45-54}{\frac{s}{\sqrt{n}}} < 0$ και επομένως $p\text{-value} > 0.5$ (αφού η κατανομή t είναι συμμετρική γύρω από το 0), δηλαδή αρκετά μεγαλύτερο από οποιοδήποτε λογικό επίπεδο σημαντικότητας. Συνεπώς, δεν προκύπτει κάποιος λόγος απόρριψης της μηδενικής υπόθεσης.

d.

Η τιμή $p\text{-value} = 0.52$ σημαίνει ότι δεν έχουμε επαρκή στοιχεία για να απορρίψουμε τη μηδενική υπόθεση, αφού είναι αρκετά μεγάλη. Ένα τέτοιο $p\text{-value}$ δείχνει ότι τα δεδομένα της έρευνας είναι συχνό να εμφανίζονται σε έναν πληθυσμό στον οποίον ισχύει η μηδενική υπόθεση. Αντίθετα, αν είχαμε ένα πολύ μικρό $p\text{-value}$ θα απορρίπταμε την μηδενική υπόθεση, αφού τα δεδομένα θα ήταν σπάνιο να εμφανιστούν σε έναν πληθυσμό για τον οποίον ισχύει η μηδενική υπόθεση.

ΑΣΚΗΣΗ 3

Έχουμε ότι $Z \sim N(0, 1)$.

a.

$$p \text{ value} = P(Z > 1.34) = 1 - \Phi(z) = 1 - \Phi(1.34) = 0.09012267$$

b.

$$p \text{ value} = P(Z < 1.34) = \Phi(z) = \Phi(1.34) = 0.9098773$$

c.

$$p \text{ value} = 1 - \Phi(z) + \Phi(-z) = 1 - \Phi(1.34) + \Phi(-1.34) = 0.1802453$$

ΑΣΚΗΣΗ 4

a.

Ισχύει ότι $C = 0.95$, οπότε $\alpha = 1 - C = 1 - 0.95 = 0.05$

$$p \text{ value} = 0.04 < \alpha \Leftrightarrow \text{απορρίπτεται η μηδενική υπόθεση} \Leftrightarrow \mu_0 = 30 \notin [\bar{x} - z_* \frac{s}{\sqrt{n}}, \bar{x} + z_* \frac{s}{\sqrt{n}}]$$

Η τελευταία ισοδυναμία προκύπτει από γνωστή ιδιότητα και επομένως προκύπτει ότι η τιμή 30 δεν περιέχεται στο 95% διάστημα εμπιστοσύνης.

b.

Σε αυτή την περίπτωση ισχύει $C = 0.90$, οπότε $\alpha = 1 - C = 1 - 0.9 = 0.1$

Πάλι $p \text{ value} = 0.04 < \alpha$, οπότε απορρίπτεται η μηδενική υπόθεση και επομένως, κάνοντας χρήση της ιδιότητας που χρησιμοποιήθηκε και στο α ερώτημα, η τιμή μ_0 δεν ανήκει στο 90% διάστημα εμπιστοσύνης.

ΑΣΚΗΣΗ 5

Αρχικά πρέπει να εξετάσουμε τα δεδομένα της εκφώνησης για να δούμε αν μπορούμε να έχουμε σωστούς και ακριβείς υπολογισμούς. Τα δείγματα προέκυψαν από τυχαία δειγματοληψία, το οποίο σημαίνει πως είναι αντιπροσωπευτικά και θα γίνουν ορθές εκτιμήσεις των διαστημάτων εμπιστοσύνης. Επίσης έχουμε $n = 25$ δείγματα ενηλίκων, επομένως αφού $n = 25 > 15$, τηρείται η προϋπόθεση για σωστό και ακριβή υπολογισμό του δειγματικού μέσου όρου και αργότερα του διαστήματος εμπιστοσύνης. Όμως το 14ο δείγμα δείχνει μια γυναίκα ενήλικα με βάρος 6 kg. Αυτό είναι μη ρεαλιστικό και συμπεραίνουμε πως έχει γίνει λάθος στην καταγραφή στατιστικών. Αυτή η μη

ρεαλιστική τιμή θα επηρεάσει σημαντικά τα διαστήματα εμπιστοσύνης που πρέπει να υπολογίσουμε. Την αφαιρούμε και συνεχίζουμε τους υπολογισμούς με τα υπόλοιπα δείγματα της εκφώνησης

a.

Αρχικά παρατηρούμε στο stemplot μαζί με τη μη ρεαλιστική τιμή πως υπάρχει ένα ατυπικό σημείο, δηλαδή ένα κενό. Αυτό μας επιβεβαιώνει τη λάθος εισαγωγή στοιχείων. Συνεπώς είναι ορθό να το αφαιρέσουμε και υπολογίζουμε το stemplot με τα υπόλοιπα 24 δείγματα.

0		6
2		
4		459
6		5789012233357
8		01233612

(με την μη ρεαλιστική τιμή)

5		459
6		5789
7		012233357
8		012336
9		12

(χωρίς την μη ρεαλιστική τιμή)

Παρατηρούμε πως στο δεύτερο stemplot η κατανομή δεν είναι σημαντικά μη συμμετρική. Άρα, σύμφωνα με τα παραπάνω και αυτό, μπορούμε να εφαρμόσουμε μεθόδους που βασίζονται στην κατανομή t.

Από την εκφώνηση έχουμε:

$$n = 24$$

Στην R υπολογίζουμε:

$$\bar{x} = 73.79167, s = 9.978146$$

$$t_* = 2.069, df = n-1 = 23$$

$$\text{Το Διάστημα Εμπιστοσύνης: } \bar{x} \pm t_* \frac{s}{\sqrt{n}}$$

Και τελικό αποτέλεσμα για το διάστημα εμπιστοσύνης 95% για την μέση τιμή μ είναι:

$$[69.57826, 78.00507]$$

b.

Όπως και πριν, έτσι και τώρα συνεχίζουμε τους υπολογισμούς με $n = 24$ δείγματα για να έχουμε πιο ακριβείς υπολογισμούς. Όπως έχουμε προαναφέρει, τα δείγματα είναι τυχαία σύμφωνα με την εκφώνηση. Επίσης, παρατηρώντας τα stemplots για άνδρες και γυναίκες, βλέπουμε πως δεν προέρχονται από σημαντικά μη συμμετρικές κατανομές.

6		8
7		2233
7		57
8		013
8		6
9		12

(Άνδρες)

5		459
6		579
7		013
8		23

(Γυναίκες)

Επομένως τα δεδομένα είναι κατάλληλα για υπολογισμό Δ.Ε.

Απο εκφώνηση έχουμε:

$$n_A = 13, n_B = 11$$

Επίσης, υπολογίζουμε με την R:

$$\bar{x}_A = 78.69231, \bar{x}_B = 68$$

$$s_A = 7.60, s_B = 9.57$$

$$t_* = 1.372184$$

$df = \min(n_A - 1, n_B - 1) = 10$, αφού έχουμε να κάνουμε με 2 δείγματα

Καθώς έχουμε να υπολογίσουμε Διάστημα Εμπιστοσύνης από μέσες τιμές 2 δειγμάτων, ο τύπος θα είναι:

$$\bar{x}_A - \bar{x}_B \pm t_* \sqrt{\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}}$$

Και τελικό αποτέλεσμα για το διάστημα εμπιστοσύνης 80% για την μέση τιμή $\bar{x}_A - \bar{x}_B$ είναι:

[5.789155 , 15.59546]

c.

Πρέπει να ελέγξουμε αν το μέσο βάρος των καπνιστών μ_1 διαφέρει πολύ σε σχέση με το μέσο βάρος των μη καπνιστών. $H_0: \mu_1 = \mu_2$, αυτό αποτελεί έναν δίπλευρο έλεγχο σημαντικότητας. Όπως έχουμε προαναφέρει, τα δεδομένα είναι $24 > 15$, επομένως είναι αρκετά και σε συνδυασμό με την τυχαιότητα που έχουν και το ότι οι κατανομές τους στα stemplots δεν φαίνονται μη συμμετρικές:

```
5 | 9
6 | 5
7 | 137
8 | 0236
9 | 2
```

(Καπνιστές)

```
5 | 45
6 | 789
7 | 022335
8 | 13
9 | 1
```

(Μη καπνιστές)

Τα δεδομένα είναι κατάλληλα για υπολογισμούς.

Από τα δεδομένα έχουμε:

$$n_1 = 10, n_2 = 14$$

Στην R υπολογίζουμε:

$$\bar{x}_1 = 76.8, \bar{x}_2 = 71.64286$$

$$s_1 = 9.975526, s_2 = 9.76341$$

$$df = \min(n_1 - 1, n_2 - 1) = 9, \text{ καθώς δουλεύουμε με 2 μεταβλητές}$$

Επίσης, έχουμε:

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} = 1.259715 \text{ και } p\text{-value} = 0.2394573$$

```
t_stat <- (m1 - m2) / sqrt(s1^2 / n1 + s2^2 / n2)
p_value <- 2 * pt(-abs(t_stat), df_c)
```

Αφού $p\text{-value} > 0.05$ τότε δεν απορρίπτεται η H_0 . Δηλαδή τα δεδομένα δεν είναι αρκετά ισχυρά για να δείξουν στατιστική διαφορά στο μέσο βάρος μεταξύ των καπνιστών και μη καπνιστών.

ΑΣΚΗΣΗ 6

a.

Αρχικά το δείγμα είναι τυχαίο και δεύτερον έχει μέγεθος $n = 20$. Επομένως η τυχαιότητα σε συνδυασμό με το γεγονός ότι $n > 15$ δείχνει πως είναι αρκετά τα δείγματα και άρα δεν απαιτείται κανονική κατανομή πληθυσμού. Στη συνέχεια βρίσκουμε με την R το stemplot για να βεβαιώσουμε ότι η κατανομή των δειγμάτων δεν είναι σημαντικά μη συμμετρική.

```
4 | 6999
5 | 012334444
5 | 67
6 | 0334
6 | 9
```

Σύμφωνα με όλα τα παραπάνω, τα δεδομένα είναι κατάλληλα

b.

Υπολογίζουμε στην R την μέση τιμή και τυπική απόκλιση και έχω ως αποτέλεσμα:

$$\bar{x} = 5.5$$

$$s = 0.6$$

c.

$$\text{Θα βρούμε το διάστημα : } \bar{x} \pm t_* \frac{s}{\sqrt{n}}$$

Από προηγούμενο ερώτημα : $\bar{x} = 5.5$, $s=0.6$

Στην R υπολογίζουμε: $t_* = 2.093024$

Και τελικό αποτέλεσμα για το διάστημα εμπιστοσύνης 95% για την μέση τιμή μ είναι:

$$[5.218781 , 5.781219]$$

ΑΣΚΗΣΗ 7

Πρέπει να ελέγξουμε ότι η μέση εκτίμηση ζημιάς μ_a του συνεργείου είναι μεγαλύτερη από τη μέση εκτίμηση ζημιάς μ_b του εμπειρογνώμονα. Αρχικά παρατηρούμε πως οι εκτιμήσεις του εμπειρογνώμονα και του συνεργείου δεν είναι ανεξάρτητες. Δηλαδή μια μεγάλη εκτίμηση ζημιάς για κάποιο αυτοκίνητο από το συνεργείο δείχνει πόσο μεγάλη είναι όντως η ζημιά σε αυτό. Αντίστοιχα, ο εμπειρογνώμονας προβλέπει μεγάλο κόστος ζημιάς στα ίδια αυτοκίνητα. Αντιθέτως, στις πιο «φθηνές» ζημιές και οι δύο προβλέψεις είναι σχετικά χαμηλές. Επομένως δεν μπορούμε να χρησιμοποιήσουμε μεθόδους για 2 ανεξάρτητα δείγματα από 2 πληθυσμούς. Θα υπολογίσουμε τις διαφορές των προβλέψεων του συνεργείου και του εμπειρογνώμονα για κάθε αυτοκίνητο και στη συνέχεια θα υπολογίσουμε p-value, έχοντας ορίσει μια μηδενική υπόθεση.

Οι διαφορές για κάθε αυτοκίνητο:

1° αυτοκίνητο: 100

2° αυτοκίνητο: 50

3° αυτοκίνητο: -50

4° αυτοκίνητο: 0

5° αυτοκίνητο: -50

6° αυτοκίνητο: 200

7° αυτοκίνητο: 250

8° αυτοκίνητο: 200

9° αυτοκίνητο: 150

10° αυτοκίνητο: 300

Υπολογισμός stemplot στην R:

```
-0 | 55
 0 | 05
 1 | 05
 2 | 005
 3 | 0
```

Έχουμε για δείγμα $n = 10$ αυτοκίνητα. Το συγκεκριμένο δείγμα είναι μικρό, καθώς $n < 15$, επομένως η ακρίβεια του αποτελέσματος δεν θα είναι πολύ μεγάλη. Έστω μ είναι η μέση τιμή της διαφοράς, τότε ο έλεγχος σημαντικότητας είναι $H_0: \mu = 0$, $H_a: \mu > 0$. Την εναλλακτική την χρησιμοποιούμε για να δούμε αν υπάρχει υπερεκτίμηση των ζημιών από το συνεργείο για τα αυτοκίνητα. Για να το διαπιστώσουμε αυτό, όπως έχει προαναφερθεί, υπολογίζουμε p-value στην R:

$n = 10, \bar{x} = 115, s = 124.8332$

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}} = 2.913182$$

p-value = 0.008610911

Το p-value είναι κατά πολύ μικρό από οποιαδήποτε λογική ανάθεση τιμής του α . Άρα για κάθε α ισχύει $p\text{-value} < \alpha$. Επομένως η μηδενική υπόθεση απορρίπτεται και καταλήγουμε ότι όντως το συνεργείο υπερεκτιμά τις τιμές του. Ακόμα και αν η κατανομή των υπερεκτιμήσεων του συνεργείου δεν ήταν κανονική, αλλά κοντά σε αυτήν, τότε πάλι θα απορρίπταμε τη μηδενική υπόθεση και θα καταλήγαμε ότι το συνεργείο φουσκώνει τις τιμές του σύμφωνα με τον εμπειρογνώμονα.

ΑΣΚΗΣΗ 8

Αρχικά εξετάζουμε τα δεδομένα που προέρχονται από το ερωτηματολόγιο 2025. Μας ενδιαφέρει η μεταβλητή number, η οποία αντιστοιχεί σε έναν ακέραιο αριθμό από το 1 έως το 100, καθώς και το φύλο (gender) των συμμετεχόντων. Κρατάμε μόνο τις έγκυρες τιμές στο διάστημα $[1, 100]$ και αφαιρούμε τυχόν ελλείπουσες παρατηρήσεις. Μετά τον καθαρισμό των δεδομένων, έχουμε δείγμα μεγέθους $n = 119$.

Το δείγμα είναι αρκετά μεγάλο ($n > 15$), επομένως σε συνδυασμό με την τυχαιότητα της συλλογής των δεδομένων μπορούμε να προχωρήσουμε σε ελέγχους σημαντικότητας και διαστήματα εμπιστοσύνης χωρίς να απαιτείται αυστηρή κανονικότητα του πληθυσμού. Από τους υπολογισμούς στην R προκύπτει δειγματική μέση τιμή $\bar{x} = 43.277$ και τυπική απόκλιση $s = 30.332$.

a.

Έλεγχος σημαντικότητας για τη μέση τιμή

Θέλουμε να ελέγξουμε αν η μέση τιμή των αριθμών που επιλέγουν οι συμμετέχοντες είναι ίση με 50. Διατυπώνουμε:

$H_0: \mu = 50$

$H_a: \mu \neq 50$

Πρόκειται για δίπλευρο έλεγχο σημαντικότητας. Εφόσον η πληθυσμιακή τυπική απόκλιση είναι άγνωστη, χρησιμοποιούμε t-έλεγχο.

Από την R έχουμε:

$t = -2.417792, df = 118$

p-value = 0.01714468

Αφού $p\text{-value} < 0.05$, απορρίπτουμε τη μηδενική υπόθεση. Συνεπώς, τα δεδομένα δείχνουν ότι η μέση τιμή των επιλεγμένων αριθμών διαφέρει στατιστικά σημαντικά από το 50.

b.

90% Διάστημα Εμπιστοσύνης για τη μέση τιμή μ

Συνεχίζουμε με τον υπολογισμό διαστήματος εμπιστοσύνης 90% για τη μέση τιμή μ . Χρησιμοποιούμε την κατανομή t με $df = 118$.

Από την R υπολογίζουμε:

$t_* = 1.65787$

Το διάστημα εμπιστοσύνης είναι:

[38.66759, 47.88703]

Παρατηρούμε ότι η τιμή 50 δεν ανήκει στο παραπάνω διάστημα, γεγονός που συμφωνεί με το αποτέλεσμα του ελέγχου σημαντικότητας του προηγούμενου ερωτήματος.

c.

Έλεγχος ομοιόμορφης κατανομής στο διάστημα $[1, 100]$

Αν οι συμμετέχοντες επέλεξαν πραγματικά τυχαία έναν ακέραιο αριθμό από το 1 έως το 100, τότε οι τιμές θα ακολουθούσαν ομοιόμορφη κατανομή. Σε αυτή την περίπτωση η θεωρητική μέση τιμή θα ήταν $\mu_0 = 50.5$ και η θεωρητική τυπική απόκλιση $\sigma \approx 28.866$.

Δεδομένου ότι η πληθυσμιακή τυπική απόκλιση είναι γνωστή, εφαρμόζουμε z-έλεγχο με:

$$H_0: \mu = 50.5$$

$$H_a: \mu \neq 50.5$$

Από τους υπολογισμούς στην R έχουμε:

$$z = -2.729517$$

$$p\text{-value} = 0.006342719$$

Εφόσον $p\text{-value} < 0.05$, απορρίπτουμε τη μηδενική υπόθεση. Τα δεδομένα δεν είναι συμβατά με την υπόθεση ότι οι αριθμοί προέρχονται από ομοιόμορφη κατανομή στο $[1, 100]$.

d.

Έλεγχος διαφοράς μέσων τιμών μεταξύ ανδρών και γυναικών

Τέλος, εξετάζουμε αν υπάρχει διαφορά στη μέση τιμή των επιλεγμένων αριθμών μεταξύ ανδρών και γυναικών. Από τα δεδομένα έχουμε:

$$n_1 = 79 \text{ άνδρες και } n_2 = 38 \text{ γυναίκες.}$$

Οι δειγματικές μέσες τιμές είναι:

$$\bar{x}_1 = 41.74684 \text{ (άνδρες)}$$

$$\bar{x}_2 = 46.00 \text{ (γυναίκες)}$$

Αντίστοιχα οι δειγματικές τυπικές αποκλίσεις είναι:

$$s_1 = 28.52146$$

$$s_2 = 33.06096$$

Διατυπώνουμε:

$$H_0: \mu_1 = \mu_2$$

$$H_a: \mu_1 \neq \mu_2$$

Χρησιμοποιούμε t-έλεγχο για δύο ανεξάρτητα δείγματα. Λαμβάνουμε βαθμούς ελευθερίας $df = \min(n_1 - 1, n_2 - 1) = 37$.

Από την R έχουμε:

$$t = -0.6805194$$

$$p\text{-value} = 0.5004122$$

Αφού $p\text{-value} > 0.05$, δεν απορρίπτουμε τη μηδενική υπόθεση. Δηλαδή τα δεδομένα δεν είναι αρκετά ισχυρά για να δείξουν στατιστικά σημαντική διαφορά στη μέση τιμή των αριθμών που επιλέγουν άνδρες και γυναίκες.